

# 数学优化

## 范数、可微性、展开

### • 向量范数

若实值函数  $\|\cdot\|: \mathbb{R}^n \rightarrow \mathbb{R}$  满足

- $\forall \mathbf{x} \in \mathbb{R}^n, \|\mathbf{x}\| \geq 0$  且  $\|\mathbf{x}\| = 0 \iff \mathbf{x} = \mathbf{0}$
- $\forall \alpha \in \mathbb{R}, \forall \mathbf{x} \in \mathbb{R}^n, \|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|$
- $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n, \|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$

则称其为向量范数, 其中  $\mathbb{R}^n$  表示  $n$  维向量空间

设  $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$

- $L_1$  范数:  $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$
- $L_2$  范数:  $\|\mathbf{x}\|_2 = \left( \sum_{i=1}^n x_i^2 \right)^{\frac{1}{2}}$
- $L_\infty$  范数:  $\|\mathbf{x}\|_\infty = \max_i |x_i|$
- $L_p$  范数:  $\|\mathbf{x}\|_p = \left( \sum_{j=1}^n |x_j|^p \right)^{\frac{1}{p}}$

### • 矩阵范数

Frobenius 范数:  $\|\mathbf{A}\|_F = \left( \sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}} = (\text{tr}(\mathbf{A}^T \mathbf{A}))^{\frac{1}{2}}$

$\mathbf{A} \in \mathbb{R}^{m \times n}$ , 诱导的矩阵范数为  $\|\mathbf{A}\| = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|}{\|\mathbf{x}\|}$

设  $\mathbf{A} = (a_{ij})_{m \times n}$ ,  $\lambda_{\mathbf{A}^T \mathbf{A}}$  表示  $\mathbf{A}^T \mathbf{A}$  的最大特征值

- $\|\mathbf{A}\|_1 = \max_j \sum_{i=1}^m |a_{ij}|$
- $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\mathbf{A}^T \mathbf{A}}}$  (谱范数)
- $\|\mathbf{A}\|_\infty = \max_i \sum_{j=1}^n |a_{ij}|$

若矩阵  $\mathbf{A}$  正定, 则条件数  $\text{cond}(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$

- 在  $L_2$  范数定义下,  $\text{cond}(\mathbf{A}) = \frac{\lambda_{\max}(\mathbf{A})}{\lambda_{\min}(\mathbf{A})}$
- 条件数是判断矩阵病态与否的一种度量, 条件数越大矩阵越病态

### • 梯度

$$\nabla f(\mathbf{x}) = \left[ \frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right]^T$$

$f$  在点  $\mathbf{x}^0$  关于  $\mathbf{p}$  的方向导数  $\frac{\partial f(\mathbf{x}^0)}{\partial \mathbf{p}} = \lim_{t \rightarrow 0^+} \frac{f(\mathbf{x}^0 + t\mathbf{p}) - f(\mathbf{x}^0)}{t}$

- $\nabla \mathbf{b}^T \mathbf{x} = \mathbf{b}$
- $\nabla \mathbf{x}^T \mathbf{A} \mathbf{x} = (\mathbf{A} + \mathbf{A}^T) \mathbf{x} \stackrel{\text{对称矩阵}}{=} 2\mathbf{A} \mathbf{x}$
- $\nabla \left( \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c \right) = \mathbf{A} \mathbf{x} + \mathbf{b}$

### • Jacobi 矩阵

$$\mathbf{h}'(\mathbf{x}) = \nabla \mathbf{h}(\mathbf{x})^T = \begin{pmatrix} \frac{\partial h_1(\mathbf{x})}{\partial x_1} & \frac{\partial h_1(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial h_1(\mathbf{x})}{\partial x_n} \\ \frac{\partial h_2(\mathbf{x})}{\partial x_1} & \frac{\partial h_2(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial h_2(\mathbf{x})}{\partial x_n} \\ \vdots & \vdots & & \vdots \\ \frac{\partial h_m(\mathbf{x})}{\partial x_1} & \frac{\partial h_m(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial h_m(\mathbf{x})}{\partial x_n} \end{pmatrix}$$

- Hessian 矩阵

$$\nabla^2 f(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 x_2} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 x_n} \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_2 x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_2^2} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_2 x_n} \\ \vdots & \vdots & & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_n x_2} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_n^2} \end{pmatrix}$$

- Taylor 展开

- 一阶展开

$f: \mathbb{R}^n \rightarrow \mathbb{R}$  连续可微, 向量  $\mathbf{p} \in \mathbb{R}^n$

$$f(\mathbf{x} + \mathbf{p}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^T \mathbf{p} + o(\|\mathbf{p}\|)$$

- 二阶展开

$f: \mathbb{R}^n \rightarrow \mathbb{R}$  二阶连续可微

$$f(\mathbf{x} + \mathbf{p}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^T \mathbf{p} + \frac{1}{2} \mathbf{p}^T \nabla^2 f(\mathbf{x}) \mathbf{p} + o(\|\mathbf{p}\|)$$

## 凸集

- 凸集的定义

- 仿射集

设  $S$  为  $n$  维欧氏空间  $\mathbb{R}^n$  中的一个集合。若对任意两点  $\mathbf{x}^{(1)}, \mathbf{x}^{(2)} \in S$  及每个实数  $\lambda \in \mathbb{R}$ , 有  $\lambda \mathbf{x}^{(1)} + (1 - \lambda) \mathbf{x}^{(2)} \in S$ , 则称  $S$  为仿射集。  $\lambda \mathbf{x}^{(1)} + (1 - \lambda) \mathbf{x}^{(2)}$  称为  $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}$  的仿射组合

■ 泛化定义:  $\forall x_1, x_2, \dots, x_k \in S, \lambda_1, \lambda_2, \dots, \lambda_k \in \mathbb{R}, \lambda_1 + \lambda_2 + \dots + \lambda_k = 1$ , 有  $\lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_k x_k \in S$

- 仿射包

$$\text{aff} S = \left\{ \lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_k x_k \left| \begin{array}{l} \forall x_1, x_2, \dots, x_k \in S \\ \lambda_1 + \lambda_2 + \dots + \lambda_k = 1 \end{array} \right. \right\}$$

- 凸集

设  $S$  为  $n$  维欧氏空间  $\mathbb{R}^n$  中的一个集合。若对任意两点  $\mathbf{x}^{(1)}, \mathbf{x}^{(2)} \in S$  及每个实数  $\lambda \in [0, 1]$ , 有  $\lambda \mathbf{x}^{(1)} + (1 - \lambda) \mathbf{x}^{(2)} \in S$ , 则称  $S$  为凸集。  $\lambda \mathbf{x}^{(1)} + (1 - \lambda) \mathbf{x}^{(2)}$  称为  $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}$  的凸组合

- 凸包

$$\text{conv} C = \left\{ \lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_k x_k \left| \begin{array}{l} \forall x_1, x_2, \dots, x_k \in S \\ \lambda_1 + \lambda_2 + \dots + \lambda_k = 1 \\ \lambda_1, \lambda_2, \dots, \lambda_k \in [0, 1] \end{array} \right. \right\}$$

- 锥

设有集合  $C \subset \mathbb{R}^n$ , 若对任一点  $x \in C$ , 当  $\lambda > 0$  时, 都有  $\lambda x \in C$ , 称  $C$  为锥

- 凸锥

任意两点  $x^{(1)}, x^{(2)} \in S$  及实数  $\lambda_1, \lambda_2 \geq 0$  都有  $\lambda_1 x^{(1)} + \lambda_2 x^{(2)} \in C$ , 称  $C$  为凸锥

- 典型凸集

- 超平面

$H = \{x \mid p^T x = \alpha\}$ , 其中  $p$  为  $n$  维列向量,  $\alpha$  为实数

- 半空间

正的闭半空间  $H^+ = \{x \mid p^T x \geq \alpha\}$

负的闭半空间  $H^- = \{x \mid p^T x \leq \alpha\}$

正的开半空间  $\dot{H}^+ = \{x \mid p^T x > \alpha\}$

负的开半空间  $\dot{H}^- = \{x \mid p^T x < \alpha\}$

- 多面体

有限个线性等式和不等式的解集

有限个半空间与超平面的交集

- 多胞形

有限点集  $\{x^0, x^1, \dots, x^m\} \subset \mathbb{R}^n$  的凸包称为多胞形

- 单纯形

$\{x^0, x^1, \dots, x^m\}$  仿射无关,  $x^1 - x^0, \dots, x^m - x^0$  线性无关, 对应的凸包称为  $m$  维单纯形, 向量  $x^i$  称为该单纯形的顶点

- 极点

非空凸集中的点  $x$  称为极点, 若  $x = \lambda x_1 + (1 - \lambda)x_2, \lambda \in (0, 1), x_1, x_2 \in S$ , 则  $x = x_1 = x_2$

- 集合的保凸运算

- 保凸运算

设  $S_1, S_2$  为  $\mathbb{R}^n$  中的两个凸集,  $\beta$  为实数, 则

- $\beta S_1 = \{\beta x \mid x \in S_1\}$  为凸集

- $S_1 + \beta = \{x + \beta \mid x \in S_1\}$  为凸集

- $S_1 \cap S_2$  为凸集

- $S_1 + S_2 = \{x^{(1)} + x^{(2)} \mid x^{(1)} \in S_1, x^{(2)} \in S_2\}$  为凸集

- $S_1 - S_2 = \{x^{(1)} - x^{(2)} \mid x^{(1)} \in S_1, x^{(2)} \in S_2\}$  为凸集

- 集合的保凸运算

函数  $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$  是仿射的, 当  $f(x) = Ax + b, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$ , 若  $S \in \mathbb{R}^n$  为凸集, 则  $f(S) = \{f(x) \mid x \in S\}$  为凸

## 凸函数

- 凸函数定义

设  $S \subset \mathbb{R}^n$  是非空凸集, 函数  $f: S \rightarrow \mathbb{R}$ , 若对任意  $x_1, x_2 \in S$ , 每一  $\lambda \in (0, 1)$  都有  $f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2)$  则称  $f$  是  $S$  上的凸函数

若对于  $\mathbf{x}_1 \neq \mathbf{x}_2$  严格成立, 则称  $f$  是  $S$  上的严格凸函数

- 一阶条件定理

设  $S \subset \mathbb{R}^n$  是非空开凸集, 函数  $f: S \rightarrow \mathbb{R}$  是可微函数, 则  $f(\mathbf{x})$  是凸函数当且仅当对任意的  $\mathbf{x}^* \in S$ , 有  $\forall \mathbf{x} \in S, f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T(\mathbf{x} - \mathbf{x}^*)$

$f(\mathbf{x})$  严格凸当且仅当  $\forall \mathbf{x} \in S, f(\mathbf{x}) > f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T(\mathbf{x} - \mathbf{x}^*)$

- 推广

设  $S \subset \mathbb{R}^n$  是非空开凸集, 函数  $f: S \rightarrow \mathbb{R}$  是可微函数, 则  $f(\mathbf{x})$  是凸函数当且仅当对任意的  $\mathbf{x}_1, \mathbf{x}_2 \in S$ , 有  $(\nabla f(\mathbf{x}_1) - \nabla f(\mathbf{x}_2))^T(\mathbf{x}_2 - \mathbf{x}_1) \geq 0$

$f(\mathbf{x})$  严格凸当且仅当对任意的  $\mathbf{x}_1, \mathbf{x}_2 \in S$ , 有  $(\nabla f(\mathbf{x}_1) - \nabla f(\mathbf{x}_2))^T(\mathbf{x}_2 - \mathbf{x}_1) > 0$

- 二阶条件定理

设  $S \subset \mathbb{R}^n$  是非空凸集, 函数  $f: S \rightarrow \mathbb{R}$  的二次可微函数, 则  $f(\mathbf{x})$  是凸函数当且仅当  $S$  上每一点的 Hessian 矩阵是半正定的

$f(\mathbf{x})$  严格凸当且仅当  $S$  上每一点的 Hessian 矩阵是正定的

- 切西瓜定理

设  $S \subset \mathbb{R}^n$  是非空凸集, 函数  $f: S \rightarrow \mathbb{R}$  的可微函数, 则  $f(\mathbf{x})$  是凸函数当且仅当对任意  $\mathbf{x} \in S$ , 任意的方向  $\mathbf{v} \in \mathbb{R}^n$ , 关于  $t$  的一元函数  $g(t) = f(\mathbf{x} + t\mathbf{v})$  为凸函数, 其中  $\text{dom}g = \{t \mid \mathbf{x} + t\mathbf{v} \in \text{dom}f\}$

- 常见函数的凹凸性

- 函数的保凸运算

- 非负加权和:  $f = w_1 f_1 + \cdots + w_m f_m$
- 仿射映射:  $g(\mathbf{x}) = f(A\mathbf{x} + \mathbf{b})$
- 逐点最大:  $f(\mathbf{x}) = \max \{f_1(\mathbf{x}), \cdots, f_m(\mathbf{x})\}$
- 函数透视:  $g(\mathbf{x}, t) = t f(\mathbf{x}/t)$
- 函数共轭:  $f^*(\mathbf{y}) = \sup_{\mathbf{x} \in \text{dom}f} (\mathbf{y}^T \mathbf{x} - f(\mathbf{x}))$
- 复合函数:  $f(\mathbf{x}) = h(g(\mathbf{x}))$ , 若  $h$  非减, 则凹凸性一致; 若  $h$  非增, 则凹凸性相反

- 凸函数与凸集的关系

- 凸函数  $f$  的水平集  $L(f, \alpha) = \{\mathbf{x} \mid \mathbf{x} \in S, f(\mathbf{x}) \leq \alpha\}, \alpha \in \mathbb{R}$  和上镜图  $\text{epi}(f) = \{(\mathbf{x}, y) \mid \mathbf{x} \in S, y \in \mathbb{R}, y \geq f(\mathbf{x})\}$  都是凸集
- 拟凸函数: 若函数  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  所有的  $\alpha$ -sublevel sets  $S_\alpha \{\mathbf{x} \mid f(\mathbf{x}) \leq \alpha, \mathbf{x} \in \text{dom}f\}$  都为凸集合, 则  $f$  为拟凸函数
- 拟凹函数: 若函数  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  所有的  $\alpha$ -superlevel sets  $S_\alpha \{\mathbf{x} \mid f(\mathbf{x}) \geq \alpha, \mathbf{x} \in \text{dom}f\}$  都为凸集合, 则  $f$  为拟凹函数
- 若  $\text{dom}f$  为凸集且  $f(\theta\mathbf{x} + (1 - \theta)\mathbf{y}) \leq \max \{f(\mathbf{x}), f(\mathbf{y})\}$ , 则  $f$  为拟凸函数

## 凸优化问题

- 凸规划

- 目标函数: 凸函数
- 可行域: 凸集

- 对凸问题，任何局部最优解都是全局最优解

## • 等价形式

- 变量替换

$$\mathbf{x} = \phi(\mathbf{z}), \tilde{f}_i(\mathbf{z}) = f_i(\phi(\mathbf{z}))$$

等价于

$$\underset{\mathbf{z}}{\text{minimize}} \quad \tilde{f}_0(\mathbf{z})$$

$$\text{subject to} \quad \tilde{f}_i(\mathbf{z}) \leq 0 \quad i = 1, \dots, m$$

$$\tilde{h}_i(\mathbf{z}) = 0 \quad i = 1, \dots, p$$

- 消除/引入等式约束

$$\underset{\mathbf{x}}{\text{minimize}} \quad f_0(\mathbf{x})$$

$$\text{subject to} \quad f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m$$

$$\mathbf{Ax} = \mathbf{b}$$

$$\mathbf{Ax} = \mathbf{b} \leftrightarrow \mathbf{x} = \mathbf{Fz} + \mathbf{x}_0$$

等价于

$$\underset{\mathbf{z}}{\text{minimize}} \quad f_0(\mathbf{Fz} + \mathbf{x}_0)$$

$$\text{subject to} \quad f_i(\mathbf{Fz} + \mathbf{x}_0) \leq 0 \quad i = 1, \dots, m$$

- 引入松弛变量

$$\underset{\mathbf{x}}{\text{minimize}} \quad f_0(\mathbf{x})$$

$$\text{subject to} \quad \mathbf{a}_i^T \mathbf{x} \leq b_i \quad i = 1, \dots, m$$

等价于

$$\underset{\mathbf{x}}{\text{minimize}} \quad f_0(\mathbf{x})$$

$$\text{subject to} \quad \mathbf{a}_i^T \mathbf{x} + s_i \leq b_i \quad i = 1, \dots, m$$

$$s_i \geq 0 \quad i = 1, \dots, m$$

- 目标函数放到约束条件

$$\underset{\mathbf{x}}{\text{minimize}} \quad f_0(\mathbf{x})$$

$$\text{subject to} \quad f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m$$

$$\mathbf{Ax} = \mathbf{b}$$

等价于

$$\underset{\mathbf{x}}{\text{minimize}} \quad t$$

$$\text{subject to} \quad f_0(\mathbf{x}) - t \leq 0$$

$$f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m$$

$$\mathbf{Ax} = \mathbf{b}$$

- 先优化某些变量

$$\underset{\mathbf{x}, \mathbf{y}}{\text{minimize}} \quad f_0(\mathbf{x}, \mathbf{y})$$

$$\text{subject to} \quad f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m$$

$$\inf_{\mathbf{x}, \mathbf{y}} f(\mathbf{x}, \mathbf{y}) = \inf_{\mathbf{x}} \tilde{f}(\mathbf{x})$$

$$\tilde{f}(\mathbf{x}) = \inf_{\mathbf{y}} f(\mathbf{x}, \mathbf{y})$$

等价于

$$\begin{aligned} & \underset{x}{\text{minimize}} && \tilde{f}_0(\mathbf{x}) \\ & \text{subject to} && f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m \end{aligned}$$

- **线性规划 (LP)**

- 标准形式:

$$\begin{aligned} & \underset{x}{\text{minimize}} && \mathbf{c}^T \mathbf{x} + d \\ & \text{subject to} && \mathbf{G}\mathbf{x} \leq \mathbf{h} \\ & && \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned}$$

- 可行域是一个多面体

## 二次规划

- **二次规划 (QP)**

$$\begin{aligned} & \underset{x}{\text{minimize}} && \frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{q}^T \mathbf{x} + r \\ & \text{subject to} && \mathbf{G}\mathbf{x} \leq \mathbf{h} \\ & && \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned}$$

- **二次约束二次规划 (QCQP)**

$$\begin{aligned} & \underset{x}{\text{minimize}} && \frac{1}{2} \mathbf{x}^T \mathbf{P}_0 \mathbf{x} + \mathbf{q}_0^T \mathbf{x} + r_0 \\ & \text{subject to} && \frac{1}{2} \mathbf{x}^T \mathbf{P}_i \mathbf{x} + \mathbf{q}_i^T \mathbf{x} + r_i \leq 0 \quad i = 1, \dots, m \\ & && \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned}$$

- **半正定规划 (SDP)**

$$\begin{aligned} & \underset{x}{\text{minimize}} && \text{tr}(\mathbf{C}\mathbf{X}) \\ & \text{subject to} && \text{tr}(\mathbf{A}_i \mathbf{X}) = b_i \\ & && \mathbf{X} \succeq 0 \\ & \underset{x}{\text{minimize}} && \mathbf{c}^T \mathbf{x} \\ & \text{subject to} && x_1 \mathbf{F}_1 + \dots + x_n \mathbf{F}_n \preceq \mathbf{G} \\ & && \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned}$$

## 对偶问题

---

- **拉格朗日**

标准形式最优化问题

$$\begin{aligned} & \underset{x}{\text{minimize}} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 0 \quad i = 1, \dots, m \\ & && h_i(x) = 0 \quad i = 1, \dots, p \end{aligned}$$

$$D = \bigcap_{i=0}^m \text{dom} f_i \cap \bigcap_{i=1}^p \text{dom} h_i$$

拉格朗日: 目标函数和约束函数的加权和

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$$

- **对偶函数**

$$g: x \in R^m \times R^p \rightarrow R$$

$$\begin{aligned}
g(\lambda, v) &= \inf_{x \in D} L(x, \lambda, v) \\
&= \inf_{x \in D} \left( f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \right)
\end{aligned}$$

对偶函数总是凹函数

- **对偶问题**

$$\underset{x}{\text{minimize}} \quad g(\lambda, v)$$

$$\text{subject to} \quad \lambda \geq 0$$

设原问题最优化目标函数值为  $p^*$ , 对偶问题为  $d^*$ , 则  $d^* \leq p^*$

对偶问题总是凸问题

- **弱对偶和强对偶**

- 弱对偶

$$d^* \leq p^*$$

$$\text{对偶间隙 } d^* - p^*$$

- 强对偶

$$d^* = p^*$$

Slater 约束规范: 对凸优化问题, 只要有一个严格可行点, 强对偶即成立

## 最优性条件

---

- **KKT 条件**

- 原问题可行

$$f_i(\mathbf{x}^*) \leq 0, i = 1, \dots, m, h_i(\mathbf{x}^*) = 0, i = 1, \dots, p$$

- 对偶问题可行

$$\lambda^* \geq 0$$

- 互补松弛条件

$$\forall i, \lambda_i^* f_i(\mathbf{x}^*) = 0$$

- 拉格朗日对  $\mathbf{x}$  求导为零

$$\nabla f_0(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i \nabla f_i(\mathbf{x}^*) + \sum_{i=1}^p v_i \nabla h_i(\mathbf{x}^*) = 0$$

## 算法

---

### 0.618 法

- **单峰函数**: 若  $\exists \alpha^* \in [a, b]$ , 使得  $f(x)$  在  $[a, \alpha^*]$  上严格递减, 在  $[\alpha^*, b]$  上严格递增, 则  $f(x)$  是  $[a, b]$  上的单峰函数
- 设  $\varphi(\alpha)$  是搜索区间  $[a_1, b_1]$  上的单峰函数, 设在第  $k$  次迭代时搜索区间为  $[a_k, b_k]$ 。取两个试探点  $\lambda_k, \mu_k \in [a_k, b_k], \lambda_k < \mu_k$ , 计算  $\varphi(\lambda_k), \varphi(\mu_k)$

- 若  $\varphi(\lambda_k) \leq \varphi(\mu_k)$ , 令  $a_{k+1} = a_k, b_{k+1} = \mu_k$
- 若  $\varphi(\lambda_k) > \varphi(\mu_k)$ , 令  $a_{k+1} = \lambda_k, b_{k+1} = b_k$

## 牛顿法

$$x^{(k+1)} = x^{(k)} - \frac{f'(x^{(k)})}{f''(x^{(k)})}$$

## 割线法

$$x^{(k+1)} = x^{(k)} - \frac{x^{(k)} - x^{(k-1)}}{f'(x^{(k)}) - f'(x^{(k-1)})} f'(x^{(k)})$$

## 梯度下降法

- 给定初始点  $x^{(1)}$
- 计算负梯度方向  $d^{(k)} = -\nabla f(x^{(k)})$
- 计算步长  $\lambda$ , 满足  $\varphi(\lambda_k) = f(x^{(1)} + \lambda_k d^{(k)}), \varphi'(\lambda_k) = 0$
- 更新  $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$
- 中止准则:  $\|\nabla f(x)\|_2 \leq \epsilon$

## 牛顿法

$$x^{(k+1)} = x^{(k)} - (\nabla^2 f(x^{(k)}))^{-1} \nabla f(x^{(k)})$$