

随机事件及概率

- 随机事件
- 随机事件的概率
- 等可能概型
- 条件概率
- 随机事件独立性

随机变量及其概率分布

- 随机变量
- 随机变量的分布函数
- 离散型随机变量
- 连续型随机变量
- 随机变量函数的分布

随机向量及其概率分布

- 二维随机向量的联合分布
- 边缘分布
- 条件分布
- 随机变量的独立性
- n 维随机向量
- 随机向量函数的分布

随机变量的数字特征

- 数学期望
- 方差
- 协方差和相关系数
- 矩和协方差矩阵

极限定理

- 大数定律
- 中心极限定律

抽样分布

- 基本概念
- 统计中的重要分布
- 正态总体中统计量的分布

参数估计

- 点估计
- 估计量的评选标准
- 区间估计
- 正态总体参数的区间估计

假设检验

- 基本概念
- 单个正态总体参数的检验

随机事件及概率

随机事件

- 概念:
 - 确定现象 / 随机现象 / 模糊现象

- 随机试验(E)
- 随机事件(基本事件 / 样本空间) / 必然事件 / 不可能事件
- 对立事件: $A \cup B = \Omega, AB = \emptyset$
- 运算规律:
 - 交换律
$$A \cup B = B \cup A$$
$$AB = BA$$
 - 结合律
$$(A \cup B) \cup C = A \cup (B \cup C) = A \cup B \cup C$$
$$(AB)C = A(BC) = ABC$$
 - 分配律
$$(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$$
$$(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$$
 - 摩根公式
$$\overline{A \cup B} = \overline{A} \cap \overline{B}$$
$$\overline{A \cap B} = \overline{A} \cup \overline{B}$$

随机事件的概率

如果在 n 次重复随机试验中, 事件 A 发生了 n_A 次, 称比值 $f_n(A) = \frac{n_A}{n}$ 为事件 A 发生的频率

等可能概型

$$P(A) = \frac{A \text{ 中所含基本事件数}}{\text{基本事件总数}} = \frac{\#A}{\#\Omega}$$

条件概率

$$P(A | B) = \frac{P(AB)}{P(B)}$$

- 全概率公式
设随机试验 E 的事件组 A_1, A_2, \dots 是样本空间 Ω 的一组划分(有穷或无穷), 假定对于每一个 i , $P(A_i) > 0$, 则对于任意事件 B , $P(B) = \sum_{i=1}^n P(A_i) P(B | A_i)$
- 贝叶斯公式
设随机试验 E 的事件组 A_1, A_2, \dots 是样本空间 Ω 的一组划分(有穷或无穷), 假定对于每一个 i , $P(A_i) > 0$, 则对于任意事件 B , 只要 $P(B) > 0$, 有 $P(A_i | B) = \frac{P(A_i B)}{P(B)} = \frac{P(A_i) P(B | A_i)}{\sum_{k=1}^n P(A_k) P(B | A_k)}$

随机事件独立性

若 $P(A \cap B) = P(A) P(B)$, 则 A 和 B 相互独立

- 独立扩张定理
事件 A_1, A_2, \dots, A_n 相互独立, 将任意多个事件替换成它们各自的对立事件后, 任然是 n 个相互独立的事件

随机变量及其概率分布

随机变量

设 E 是一个随机试验， $\Omega = \{\omega\}$ 是其样本空间，如果对每一个 $\omega \in \Omega$ 有唯一的实数 $X(\omega)$ 与之对应，则称 X 是 E 的一个随机变量

随机变量的分布函数

设 X 是一个随机变量， $x \in \mathbb{R}$ 是一个实数，函数 $F(x) = P(X \leq x)$ 就称为随机变量 X 的概率分布函数，简称分布函数

- 分布函数的定义域为一切实数
- 分布函数在 x 处的取值所表示的是随机变量 X 在 $(-\infty, x]$ 上的概率
- 性质:
 - 单调不减，若 $x_1 < x_2$ ，则 $F(x_1) \leq F(x_2)$
 - $0 \leq F(x) \leq 1, F(-\infty) = 0, F(+\infty) = 1$
 - 右连续， $F(x+0) = F(x)$
- 常用公式:
 - $P(X \leq b) = F(b)$
 - $P(a \leq X \leq b) = F(b) - F(a)$
 - $P(X > b) = 1 - F(b)$
 - $P(X < b) = F(b-0)$
 - $P(X = b) = F(b) - F(b-0)$

离散型随机变量

- 分布列 / 分布律:

$$P(X = x_k) = p_k$$

X	x_1	x_2	\cdots	x_k	\cdots
P	p_1	p_2	\cdots	p_k	\cdots

- 分布函数:

$$F(x) = P(X \leq x) = \sum_{x_k \leq x} p_k$$

(0-1)分布:

$$P(X = x) = p^x(1-p)^{1-x}, x = 0, 1$$

- 二项分布:

把试验 E 在相同的条件下重复进行 n 次各次试验的结果有限且互不影响，则称这 n 次试验为 **n 次独立试验**

如果每次试验只有两个结果，则 n 次独立试验又称为 **n 重贝努里试验**

X 为 n 重贝努里试验中成功的次数，

$$P(X = k) = C_n^k p^k (1-p)^{n-k}, k = 0, 1, 2, \cdots, n$$

记为 $X \sim B(n, p)$

当 k 为最可能成功的次数时，称 $P(X = k)$ 为**二项分布的中心项**

- 泊松分布:

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, 2, \cdots, \lambda > 0$$

记为 $X \sim P(\lambda)$

- $B(n, p)$ 中 n 较大, p 较小时, 趋近于泊松分布, $\lambda = np$
- **超几何分布:**

$$P(X = k) = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}, k = 0, 1, 2, \dots, \min\{n, M\}$$
 记为 $X \sim H(N, M, n)$
- **几何分布:**

$$P(X = k) = pq^{k-1}, k = 1, 2, 3, \dots$$
 记为 $X \sim G(p)$
- **负二项分布 / 帕斯卡分布:**

$$P(X = k) = C_{r-1}^{k-1} p^r (1-p)^{k-r}, k = r, r+1, \dots$$
 记为 $X \sim NB(r, p)$

连续型随机变量

若存在非负可积函数 $f(x)$, 使得对于任一实数 x , 有 $F(x) = \int_{-\infty}^x f(t) dt$, 则称 X 是 **连续型随机变量**, 其中函数 $f(x)$ 称为 X 的 **概率密度函数(PDF)**, 简称为 **概率密度**

- $f(x) \geq 0, x \in \mathbb{R}$
- $\int_{-\infty}^{+\infty} f(x) dx = 1$
- $F'(x) = f(x)$
- $P(X = x_0) = 0$
- $P(X \in I) = \int_I f(x) dx$

- **均匀分布:**

$$f(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{其它} \end{cases}$$

记为 $X \sim U[a, b]$

- **指数分布:**

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

记为 $X \sim e(\lambda)$

$$P(X > n+k | X > n) = P(X > k)$$

- **正态分布:**

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

记为 $X \sim N(\mu, \sigma^2)$

- 当 $x = \mu$ 时曲线处于最高点
 σ 越大, 曲线越矮胖
- $N(0, 1)$ 为 **标准正态分布**
- 设 $X \sim N(\mu, \sigma^2)$, 则 $Y = \frac{X-\mu}{\sigma} \sim N(0, 1)$

$$F(x) = P(X \leq x) = P\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right)$$
- $\Phi(-x) = 1 - \Phi(x)$
- α 分位点 $x_\alpha: P(X > x_\alpha) = \alpha$

随机变量函数的分布

已知随机变量 X 的分布, $g(x)$ 是一连续函数, 求 $Y = g(x)$ 的分布

- X 为离散型随机变量
- X 为连续型随机变量
 - 设 X 的密度函数为 $f_X(x)$, 则随机变量 $Y = g(X)$ 的分布函数为

$$F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = \int_{g(x) \leq y} f_X(x) dx$$

$$f_Y(y) = \frac{d}{dy} F_Y(y)$$
 - 设 X 的概率密度函数为 $f_X(x)$, 若 $g'(x) > 0$ 或 $g'(x) < 0$, 记 $x = h(y)$ 为 $y = g(x)$ 的反函数, 则 $Y = g(X)$ 概率密度为

$$f_Y(y) = \begin{cases} f_X(h(y)) |h'(y)| & y \in g(R) \\ 0 & \text{其它} \end{cases}$$
 其中 $g(R) = \{g(x) \mid x \in R\}$ 为 $g(x)$ 的值域

随机向量及其概率分布

二维随机向量的联合分布

设 $\Omega = \{\omega\}$ 是随机试验 E 的样本空间, X 和 Y 是定义在 Ω 上的随机变量, 由它们构成的二维向量 (X, Y) 称为 E 的一个二维随机向量

- **联合分布函数**

$$F(x, y) = P(X \leq x, Y \leq y)$$

- $0 \leq F(x, y) \leq 1$

$$F(-\infty, y) = 0$$

$$F(x, -\infty) = 0$$

$$F(-\infty, -\infty) = 0$$

$$F(+\infty, +\infty) = 1$$
- $F(x_1, y) \leq F(x_2, y) \quad x_1 < x_2$

$$F(x, y_1) \leq F(x, y_2) \quad y_1 < y_2$$
- $F(x, y) = F(x+0, y)$

$$F(x, y) = F(x, y+0)$$
- $P(x_1 < X \leq x_2, y_1 < Y \leq y_2) = F(x_2, y_2) - F(x_2, y_1) + F(x_1, y_1) - F(x_1, y_2)$

- **二维离散型随机变量**

- $p_{ij} \geq 0$
- $\sum_i \sum_j p_{ij} = 1$
- $F(x, y) = \sum_{x_i \leq x} \sum_{y_j \leq y} p_{ij}$

- **连续型二维变量**

$$F(x, y) = \int_{-\infty}^y \int_{-\infty}^x f(x, y) dx dy$$

- $f(x, y) \geq 0$
- $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1$
- $f(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y}$
- 设 G 为平面 xy 上的一个区域, 则 $P\{(X, Y) \in G\} = \iint_G f(x, y) dx dy$

- **二维均匀分布**

设 G 为平面 xy 上的一个区域, S 是 G 的面积, 则

$$f(x, y) = \begin{cases} \frac{1}{S} & (x, y) \in G \\ 0 & (x, y) \notin G \end{cases}$$

- **二维正态分布**

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-r^2}} \exp \left[-\frac{1}{2(1-r^2)} \left(\frac{(x-\mu_1)^2}{\sigma_1^2} - 2r\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right) \right]$$

$$-\infty < \mu_1, \mu_2 < +\infty, \sigma_1 > 0, \sigma_2 > 0, |r| < 1$$

$$\text{记作 } (X, Y) \sim N(\mu_1, \sigma_1^2; \mu_2, \sigma_2^2; r)$$

- **Γ 函数**

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx, \alpha > 0$$

$$\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$$

边缘分布

- **定义**

$$F_1(x) = F_X(x) = F(x, +\infty)$$

$$F_2(y) = F_Y(y) = F(+\infty, y)$$

- **边缘分布率**

若联合分布律为 $P(X = x_i, Y = y_j) = p_{ij}, i, j = 1, 2, \dots$, 则

$$X \text{ 的边缘分布率 } P(X = x_i) = \sum_{j=1}^{\infty} p_{ij} = p_i, i = 1, 2, \dots$$

$$Y \text{ 的边缘分布率 } P(Y = y_j) = \sum_{i=1}^{\infty} p_{ij} = p_j, j = 1, 2, \dots$$

- **边缘概率密度**

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$$

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$$

条件分布

- **定义**

- 连续型随机变量

$$F_{Y|X}(y | x) = P(Y \leq y | X = x) = \frac{P(X=x, Y \leq y)}{P(X=x)} = \lim_{\alpha \rightarrow 0} \frac{F(x, y) - F(x - \alpha, y)}{F(x, +\infty) - F(x - \alpha, +\infty)}$$

- 离散型随机变量

$$P(Y = j | X = i) = \frac{P(X=i, Y=j)}{P(X=i)} = \frac{p_{ij}}{p_i}$$

- **条件概率密度**

$$f_{Y|X}(y | x) = \frac{f(x, y)}{f_X(x)}$$

随机变量的独立性

- **定义**

若 $F(x, y) = F_X(x) \cdot F_Y(y)$, 则称 X 和 Y 是相互独立的

- **充要条件**

- $P(X = x_i, Y = y_j) = P(X = x_i) P(Y = y_j)$

- $f(x, y) = f_X(x) f_Y(y)$

n 维随机向量

- **定义**

- 联合分布函数

$$F(x_1, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n)$$

- 联合分布律

$$P(X_1 = x_i^{(1)}, \dots, X_n = x_j^{(n)}) = p_{i \dots j}$$

- 联合概率密度

$$F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f(x_1, \dots, x_n) dx_1 \dots dx_n$$

随机向量函数的分布

- 二维连续型随机变量

$$Z = g(X, Y)$$

- 分布函数

$$F_Z(z) = P(Z \leq z) = P(g(X, Y) \leq z) = \iint_{g(x, y) \leq z} f(x, y) dx dy$$

- 概率密度

$$f_Z(z) = \frac{d}{dz} F_Z(z)$$

- 卷积公式

$$f_X \cdot f_Y = f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx = \int_{-\infty}^{+\infty} f_X(z-y) f_Y(y) dy$$

随机变量的数字特征

数学期望

- 定义

- 设离散型随机变量 X 的分布律为 $P(X = x_i) = p_i, i = 1, 2, \dots$, 若级数 $\sum_{i=1}^{\infty} |x_i| p_i$ 收敛, 则 X 的数

$$学期望存在, EX = \sum_{i=1}^{\infty} x_i p_i$$

- 设连续型随机变量 X 的分布律为 $f(x)$, 若积分 $\int_{-\infty}^{+\infty} |x| f(x) dx$ 收敛, 则 X 的数学期望存在, $EX = \int_{-\infty}^{+\infty} x f(x) dx$

- 常见数学期望

- $(0, 1)$ 分布

$$EX = p$$

- 二项分布 $B(n, p)$

$$P(X = k) = C_n^k p^k (1-p)^{n-k}, k = 0, 1, 2, \dots, n$$

$$EX = np$$

- 泊松分布 $P(\lambda)$

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, 2, \dots, \lambda > 0$$

$$EX = \lambda$$

- 几何分布 $G(p)$

$$P(X = k) = pq^{k-1}, k = 1, 2, 3, \dots$$

$$EX = \frac{1}{p}$$

- 超几何分布 $H(N, M, n)$

$$P(X = k) = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}, k = 0, 1, 2, \dots, \min\{n, M\}$$

$$EX = \frac{nM}{N}$$

- 均匀分布 $U(a, b)$

$$f(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{其它} \end{cases}$$

$$EX = \frac{a+b}{2}$$

- 指数分布 $e(\lambda)$

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

$$EX = \frac{1}{\lambda}$$

- 正态分布 $N(\mu, \sigma^2)$

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$EX = \frac{2\sigma}{\sqrt{2\pi}} + |\mu| = \mu < +\infty$$

• 随机变量函数的数学期望

- 设 $Y = g(X)$

- 若 X 为离散型随机变量, 其分布律为 $P(X = x_k) = p_k, k = 1, 2, \dots$, 则 $EY = \sum_{k=1}^{\infty} g(x_k) p_k$

- 若 X 为连续型随机变量, 其密度函数为 $f(x)$, 则 $EY = \int_{-\infty}^{+\infty} g(x) f(x) dx$

- 设 $Z = g(X, Y)$

- 若 (X, Y) 为离散型随机变量, 则 $EY = \sum_{j=1}^{\infty} \sum_{i=1}^{\infty} g(x_i, y_j) p_{ij}$

- 若 (X, Y) 为连续型随机变量, 则 $EY = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy$

• 数学期望的性质

- $EC = C$

- $E(CX) = CE X$

- $E(X + Y) = EX + EY$

$$E\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n EX_i$$

$$E(aX + b) = aEX + b$$

- 若 X, Y 相互独立, 则 $E(X \cdot Y) = EX \cdot EY$

方差

• 定义

$$DX = E(X - EX)^2 = EX^2 - (EX)^2$$

• 常见方差

- $(0, 1)$ 分布

$$DX = pq$$

- 二项分布 $B(n, p)$

$$DX = np(1 - p)$$

- 泊松分布 $P(\lambda)$

$$DX = \lambda$$

- 几何分布 $G(p)$

$$DX = \frac{q}{p^2}$$

- 均匀分布 $U(a, b)$

$$DX = \frac{(b-a)^2}{12}$$

- 指数分布 $e(\lambda)$
 $DX = \frac{1}{\lambda^2}$
- 正态分布 $N(\mu, \sigma^2)$
 $DX = \sigma^2$

• 方差的性质

- $DC = 0$
- $D(aX + b) = a^2 DX$
- 若 X, Y 相互独立, 则 $D(aX \pm bY) = a^2 DX + b^2 DY$
- 标准化随机变量 $X^* = \frac{X - EX}{\sqrt{DX}}$, $EX^* = 0$, $DX^* = 1$
- $DX \leq E(X - C)^2$, $C = EX$ 时取等号
- $DX = 0 \iff P(X = EX) = 1$

• 不等式

- 切比雪夫不等式
 $\forall \varepsilon > 0, P(|X - EX| \geq \varepsilon) \leq \frac{DX}{\varepsilon^2}$
- 马尔可夫不等式
 $\forall \varepsilon > 0, P(|X| \geq \varepsilon) \leq \frac{E|X|^k}{\varepsilon^k} (k = 1, 2, \dots)$

协方差和相关系数

• 定义

$$\text{Cov}(X, Y) = E(X - EX)(Y - EY) = EXY - EXEY$$

$$\text{相关系数 } \rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{DX \cdot DY}}$$

- 当 $\rho_{XY} = 0$ 时, 称 X, Y 不相关
- X, Y 相互独立, 则其一定不相关; 但若 X, Y 不相关, 却未必相互独立

• 协方差的性质

- $\text{Cov}(X, Y) = \text{cov}(Y, X)$
- $\text{Cov}(X, X) = DX$
- $\text{Cov}(aX, bY) = ab \text{Cov}(X, Y)$
- $\text{Cov}(X, C) = 0$
- $\text{Cov}\left(\sum_{i=1}^n c_i x_i, Y\right) = \sum_{i=1}^n c_i \text{Cov}(X_i, Y)$

• 相关系数

- $|\rho_{XY}| \leq 1$
- $|\rho_{XY}| = 1 \iff \exists a, b, a \neq 0, P(Y = aX + b) = 1$

矩和协方差矩阵

• 矩

随机变量各种数学期望的集中称呼, 反映了概率在随机变量空间上的分布。

- $\alpha_k = EX^k$ 是 X 的 k 阶原点矩
 - $\beta^k = E(X - EX)^k$ 是 X 的 k 阶中心矩
 - $EX^k Y^l$ 是 X 和 Y 的 $(k + l)$ 阶混合原点矩
 - $\gamma_{kl} = E(X - EX)^k (Y - EY)^l$ 是 X 和 Y 的 $(k + l)$ 阶混合中心矩
- 数学期望 EX 为 X 的 1 阶原点矩
 方差 DX 为 X 的 2 阶中心矩

协方差 $\text{Cov}(X, Y)$ 为 X 和 Y 的 $(1+1)$ 阶混合中心矩

若高阶矩存在, 则低阶矩一定存在, 如方差存在则期望一定存在。

- **协方差矩阵**

设 $X = (X_1, X_2, \dots, X_n)$ 是 n 维随机向量,

$\mu = (\mu_1, \mu_2, \dots, \mu_n), \mu_i = EX_i, i = 1, 2, \dots, n$ 称为 X 的期望向量

$\sigma_{ij} = E(X_i - \mu_i)(X_j - \mu_j)$ 为 X_i 和 X_j 的协方差

则称 n 阶矩阵 $\Sigma = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1n} \\ \vdots & & \vdots \\ \sigma_{n1} & \cdots & \sigma_{nn} \end{bmatrix}$ 为 X 的协方差矩阵

- $\sigma_{ii} = DX_i$
- $\sigma_{ij} = \sigma_{ji}$
- $\forall t = (t_1, t_2, \dots, t_n), t \sum t^T = \sum_{i,j=1}^n t_i \sigma_{ij} t_j \geq 0$
- $\sigma_{ij}^2 \leq \sigma_{ii} \cdot \sigma_{jj}$

- **n 维正态分布**

n 维随机向量 $X = (X_1, X_2, \dots, X_n)$ 的联合概率密度为

$$f(x) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left[-\frac{1}{2} (x - \mu) \Sigma^{-1} (x - \mu)^T \right], \text{ 其中}$$

$x = (x_1, x_2, \dots, x_n), \mu = (\mu_1, \mu_2, \dots, \mu_n), \Sigma = (\sigma_{ij})_{n \times n}, \Sigma$ 正定, $|\Sigma|$ 是 Σ 的行列式, 则称 X 服从 n 维正态分布, 记为 $X \sim N(\mu_{1 \times n}, \Sigma_{n \times n})$

- $X \sim N(\mu_{1 \times n}, \Sigma_{n \times n}) \iff \forall l = (l_1, l_2, \dots, l_n), Xl^T \sim N(\mu l^T, \Sigma l^T)$
- $C_{m \times n}$ 为实矩阵, $X \sim N(\mu_{1 \times n}, \Sigma_{n \times n}) \implies Y = XC^T \sim N(\mu C^T, \Sigma C^T)$
- X_1, X_2, \dots, X_n 相互独立, $X \sim N(\mu_{1 \times n}, \Sigma_{n \times n}) \iff \Sigma$ 为对角矩阵

极限定理

大数定律

- **定义**

- 设 $\{X_n\} (n = 1, 2, \dots)$ 为一随机变量序列, X 为随机变量, 若对于 $\forall \varepsilon > 0$, 有 $\lim_{n \rightarrow \infty} P\{|X_n - X| \geq \varepsilon\} = 0$, 则称序列 $\{X_n\}$ 依概率收敛于 X , 记作 $\{X_n\} \xrightarrow{P} X$
 - $A_n = \{|X_n - X| < \varepsilon\}, p_n = P(A_n)$, 则 $p_n \rightarrow 1 (n \rightarrow \infty)$ 时, X_n 以很大的可能性靠近 X , 其中 ε 为误差 (随机性消失)
- 设 $\{X_n\} (n = 1, 2, \dots)$ 为一随机变量序列, 数学期望 EX_n 存在, 记 $\overline{X_n} = \frac{1}{n} \sum_{k=1}^n X_k$, 若 $\overline{X_n} \xrightarrow{P} E\overline{X_n}$, 则称序列 $\{X_n\}$ 服从大数定律

- **切比雪夫大数定律**

设 $X_1, X_2, \dots, X_n, \dots$ 为相互独立的随机变量所构成的序列, 其中

$EX_k = \mu_k, DX_k \leq C < +\infty (k = 1, 2, \dots, n, \dots)$, 则 $\forall \varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P \left(\left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n \mu_k \right| \geq \varepsilon \right) = 0$$

- 相互独立, 期望存在, 方差有限, 算术平均值依概率收敛到它本身的数学期望

- **辛钦大数定律**

$\{X_n\}$ 独立同分布, $EX_n = \mu (n = 1, 2, \dots)$ 存在, 则 $\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P \left(\left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| \geq \varepsilon \right) = 0$

- 切比雪夫大数定律加上同分布 (注意这时方差不要求存在)

- **伯努利大数定律**

设 n_A 是 n 次独立重复试验中事件 A 发生的次数, p 是事件 A 在每次试验中发生的概率, 则 $\forall \varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{n_A}{n} - p\right| \geq \varepsilon\right) = 0$$

- 辛钦大数定律加上同分布到 $(0-1)$ 分布
- 伯努利定律说明, 事件 A 发生的频率 $\frac{n_A}{n}$ 以概率收敛到事件 A 发生的概率 p , 这就以严格的数学形式表达了频率的稳定性。就是说, 当 n 很大时, 事件 A 发生的频率与概率有较大的差别的可能性很小, 因而在实际中便可以用频率来代替概率。

中心极限定律

• 定义

相互独立的随机变量序列 $\{X_n\}$, 设 $EX_n, DX_n (n = 1, 2, \dots)$ 存在, 令 $Y_n = \frac{\sum_{i=1}^n EX_i - \sum_{i=1}^n X_i}{\sqrt{\sum_{i=1}^n DX_i}}$, 若

$$\lim_{n \rightarrow \infty} P\{Y_n \leq x\} = \Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt \text{ 成立, 则称 } \{X_n\} \text{ 服从中心极限定理}$$

• 林德贝格定理

设 $\{X_n\}$ 相互独立, 数学期望和方差存在 $EX_k = \mu_k, DX_k = \sigma_k^2 (k = 1, 2, \dots, n, \dots)$, 记 $B_n^2 = \sum_{k=1}^n \sigma_k^2$

, 若 $\forall \varepsilon > 0$, 有 $\lim_{n \rightarrow \infty} \frac{1}{B_n^2} \sum_{k=1}^n \int_{|x-\mu_k| \geq \varepsilon B_n} (x - \mu_k)^2 dF_k(x) = 0$, 则 $\{X_n\}$ 服从中心极限定理

- 相互独立, 期望方差存在, 满足林德贝格条件, 序列和的标准化随机变量在 n 很大的时候满足标准正态分布
- 某随机变量由大量相互独立的随机因素的综合影响所成, 且每一个别因素在总的影响中所起的作用都很小, 这种变量往往近似地服从正态分布
- 记 $B_n^2 = \sum_{k=1}^n \sigma_k^2$, 若 $\forall \varepsilon > 0$, 有 $\lim_{n \rightarrow \infty} \frac{1}{B_n^2} \sum_{k=1}^n \int_{|x-\mu_k| \geq \varepsilon B_n} (x - \mu_k)^2 dF_k(x) = 0$ 件就是对每一个子因素影响都很小的要求条件

• 独立同分布的中心极限定理

设 $\{X_n\}$ 独立同分布, 数学期望和方差存在 $EX_k = \mu, DX_k = \sigma^2 < +\infty (k = 1, 2, \dots)$, 则 $\forall \varepsilon \in \mathbb{R}$,

$$\lim_{n \rightarrow \infty} P\left(\frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \leq x\right) = \Phi(x)$$

- 林德贝格定理加上同分布

• 德莫佛-拉普拉斯定理

设随机变量 μ_n 服从二项分布 $B(n, p)$, 对于 $\forall x$, 有

$$\lim_{n \rightarrow \infty} P\left(\frac{\mu_n - np}{\sqrt{np(1-p)}} \leq x\right) = \Phi(x)$$

- 应用

令 μ_n 是 n 重伯努利试验中事件 A 发生的次数, 则 $\mu_n \sim B(n, p)$, 其中 $p = P(A)$

$$P\left(\left|\frac{\mu_n}{n} - p\right| < \varepsilon\right) = 2\Phi\left(\varepsilon \sqrt{\frac{n}{pq}}\right) - 1$$

- 若 $\eta_n \sim B(n, p)$, 则当 $n \rightarrow \infty$, p 不是很小(如0.5)时, η_n 近似服从正态分布 $N(np, np(1-p))$; p 很小时用 $\lambda = np$ 的泊松分布更精确

抽样分布

基本概念

• 总体

我们把所研究的全部元素组成的集合称作母体或总体，总体中的每一个元素称为个体

我们只研究感兴趣的某个或者几个指标（记为 X ），因此把这些指标的分布称为总体的分布，记为 $X \sim F(x)$

• 个体

设总体 X 具有分布函数 $F(x)$ ，若 X_1, X_2, \dots, X_n 是具有分布函数 $F(x)$ 的相互独立的随机向量，则称其为总体 F （或总体 X ）的简单随机样本，简称样本，它们的观察值 x_1, x_2, \dots, x_n 称为样本观察值，又称为 X 的 n 个独立的观察值

• 统计量

设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本， $g(X_1, X_2, \dots, X_n)$ 是一个与总体分布中未知参数无关的样本的连续函数，则称 $g(X_1, X_2, \dots, X_n)$ 为统计量

统计量是样本的函数，它是一个随机变量，如果 x_1, x_2, \dots, x_n 是样本观察值，则 $g(x_1, x_2, \dots, x_n)$ 是统计量 $g(X_1, X_2, \dots, X_n)$ 的一个观察值

◦ 常用统计量

- 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
- 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
- 样本 k 阶原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, k = 1, 2, \dots$
- 样本 k 阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, k = 2, 3, \dots$
 - 当样本容量很大时， $B_2 \approx S^2$
 - 总体 X 的 k 阶矩存在，则当 n 很大时， A_k 依概率收敛到 a_k
 - 样本的联合分布
 - 若 $X \sim F(x), X_1, X_2, \dots, X_n$ 为 F 的一个样本，则 X_1, X_2, \dots, X_n 的联合分布函数为 $F^*(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$
 - 若总体 X 是离散型随机变量，其分布律为 $p_x = P(X = x), x = x_1, x_2, \dots$ ，则 X_1, X_2, \dots, X_n 的联合分布函数为 $P(X_1 = y_1, \dots, X_n = y_n) = \prod_{i=1}^n F(X_i = y_i)$ ，其中 $y_i = x_1, x_2, \dots$
 - 若 X 具有概率密度 $f(x)$ ，则 X_1, X_2, \dots, X_n 的联合分布函数为 $f^*(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$
 - 设 X_1, \dots, X_n 是总体 X 的样本， $EX = \mu, DX = \sigma^2$ 存在，
$$\begin{cases} E\bar{X} = \mu \\ D\bar{X} = \frac{\sigma^2}{n} \end{cases} \begin{cases} ES^2 = \sigma^2 \\ DS^2 = \frac{2\sigma^4}{n-1} \end{cases}$$
$$\bar{X} \xrightarrow{P} \mu, S^2 \xrightarrow{P} \sigma^2$$

统计中的重要分布

统计量 $g(X_1, X_2, \dots, X_n)$ 的分布称为抽样分布

• χ^2 -分布

- 定义

设 X_1, X_2, \dots, X_n 来自总体 $N(0, 1)$ 的样本, 则称统计量 $\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$ 服从自由度为 n 的 χ^2 分布, 记作 $\chi^2 \sim \chi^2(n)$

- $\chi^2(n)$ 概率密度为 $f(y) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} y^{\frac{n}{2}-1} e^{-\frac{y}{2}} & y > 0 \\ 0 & y \leq 0 \end{cases}$

- Γ 分布和 $\chi^2(n)$ 分布关系

$$\chi^2 = \sum_{i=1}^n X_i^2 \sim \Gamma\left(\frac{n}{2}, \frac{1}{2}\right)$$

- 性质

- 若 $\chi_1^2 \sim \chi^2(m), \chi_2^2 \sim \chi^2(n)$, 且 χ_1^2, χ_2^2 独立, 有 $\chi_1^2 + \chi_2^2 \sim \chi^2(m+n)$
- 若 $\chi^2 \sim \chi^2(n)$, 则 $E(\chi^2) = n, D(\chi^2) = 2n$

- χ^2 分布的上 α 分位点

对于给定整数 $\alpha, 0 < \alpha < 1, P(\chi^2 > \chi_{\alpha}^2(n)) = \int_{\chi_{\alpha}^2(n)}^{+\infty} f(y) dy = \alpha$ 的点 $\chi_{\alpha}^2(n)$ 为 $\chi^2(n)$ 分布的上 α 分位点

- **t -分布**

- 定义

设 $X \sim N(0, 1), Y \sim \chi^2(n)$, 且 X, Y 相互独立, 则称 $T = \frac{X}{\sqrt{\frac{Y}{n}}}$ 服从自由度为 n 的 t -分布, 记作 $T \sim t(n)$

- $t(n)$ 概率密度为 $f(t) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, -\infty < t < +\infty$

- $\lim_{n \rightarrow \infty} f(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}$, 即当 n 充分大时, t -分布近似 $N(0, 1)$ 分布

- t -分布的上 α 分位点

对于给定整数 $\alpha, 0 < \alpha < 1, P(t > t_{\alpha}(n)) = \int_{t_{\alpha}(n)}^{+\infty} f(t) dt = \alpha$ 的点 $t_{\alpha}(n)$ 为 $t(n)$ 分布的上 α 分位点

- $t_{1-\alpha}(n) = -t_{\alpha}(n)$

- **F -分布**

- 定义

设 $U \sim \chi^2(m), V \sim \chi^2(n)$, 且 U, V 相互独立, 则称 $F = \frac{\frac{U}{m}}{\frac{V}{n}}$ 服从自由度为 (m, n) 的 F -分布, 记作 $F \sim F(m, n)$

- F 分布的概率密度为 $\psi(y) = \begin{cases} \frac{\Gamma(\frac{m+n}{2}) \left(\frac{m}{n}\right)^{\frac{m}{2}} y^{\frac{m}{2}-1}}{\Gamma(\frac{m}{2}) \Gamma(\frac{n}{2}) \left(1 + \frac{m}{n} y\right)^{\frac{m+n}{2}}} & y > 0 \\ 0 & y \leq 0 \end{cases}$

- 性质

- 若 $F \sim F(m, n)$, 则 $\frac{1}{F} \sim F(n, m)$

- F -分布的上 α 分位点

对于给定整数 $\alpha, 0 < \alpha < 1, P(F > F_{\alpha}(m, n)) = \alpha$ 的点 $F_{\alpha}(m, n)$ 为 F -分布的上 α 分位点

- $F_{1-\alpha}(m, n) = \frac{1}{F_{\alpha}(n, m)}$

正态总体中统计量的分布

- 单个正态总体

设 (X_1, \dots, X_n) 为来自总体 $N(\mu, \sigma^2)$ 的一组容量为 n 的样本, 令

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \text{ 则}$$

- $U = \frac{\bar{X} - \mu}{\sigma} \sqrt{n} \sim N(0, 1)$
- \bar{X} 与 S^2 相互独立
- $\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 \sim \chi^2(n-1)$
- $T = \frac{\bar{X} - \mu}{S} \sqrt{n} \sim t(n-1)$

• 两个正态总体

设 (X_1, \dots, X_m) 为来自总体 $X \sim N(\mu_1, \sigma_1^2)$ 的一组容量为 m 的样本, (Y_1, \dots, Y_n) 为来自总体 $Y \sim N(\mu_2, \sigma_2^2)$ 的一组容量为 n 的样本, 两组样本相互独立, 令

$$\bar{X} = \frac{1}{m} \sum_{i=1}^m X_i, S_{1m}^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2, \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i, S_{2n}^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2, \text{ 则}$$

- $\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}} \sim N(0, 1)$
- $\frac{(m-1)S_{1m}^2}{\sigma_1^2} + \frac{(n-1)S_{2n}^2}{\sigma_2^2} \sim \chi^2(m+n-2)$
- $\frac{\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}}}{\sqrt{\frac{\frac{(m-1)S_{1m}^2}{\sigma_1^2} + \frac{(n-1)S_{2n}^2}{\sigma_2^2}}{m+n-2}}} \sim t(m+n-2)$
- $\frac{\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}}}{\sqrt{\frac{(m-1)S_{1m}^2 + (n-1)S_{2n}^2}{m+n-2} \sqrt{\frac{1}{m} + \frac{1}{n}}}} \sim t(m+n-2), \sigma_1 = \sigma_2$
- $\frac{S_{1m}^2}{S_{2n}^2} \frac{\sigma_2^2}{\sigma_1^2} \sim F(m-1, n-1)$

参数估计

点估计

• 问题的提法

设总体 X 的分布函数 $F(x; \theta)$ 的形式为已知, θ 为待估参数, X_1, X_2, \dots, X_n 为 X 的一个样本, x_1, x_2, \dots, x_n 为相应的一个样本值

点估计问题及为构造一个统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$, 用它的观察值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 来估计未知参数 θ , 称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 的估计量, $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的估计值

• 矩估计法

设总体 X 的分布函数为 $F(x; \theta_1, \theta_2, \dots, \theta_k)$, 称 $\begin{cases} \alpha_r(\theta_1, \theta_2, \dots, \theta_k) = EX^r = A_r = \frac{1}{n} \sum_{i=1}^n X_i^r \\ r = 1, 2, \dots, k \end{cases}$ 的解

$\hat{\theta}(X_1, X_2, \dots, X_n)$ 为 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 的矩估计量

- 样本原点矩依概率收敛于相应的总体原点矩, 而样本矩的连续函数依概率收敛于相应的总体矩的连续函数, 所以所有的矩估计都有依概率收敛这一性质 (相合性)

• 极大似然估计法

总体 $X \sim f(x; \theta_1, \theta_2, \dots, \theta_k)$, $L(\theta_1, \theta_2, \dots, \theta_k) = \prod_{i=1}^n f(x_i; \theta_1, \theta_2, \dots, \theta_k)$ 称为参数 $(\theta_1, \theta_2, \dots, \theta_k)$ 的似然函数

- 若似然函数 $L(\theta_1, \theta_2, \dots, \theta_k)$ 在 $\hat{\theta}_i(x_1, x_2, \dots, x_n)$ 处取最大值, 则称 $\hat{\theta}_i$ 为 θ_i 的极大似然估计值, $\hat{\theta}_i(X_1, X_2, \dots, X_n)$ 为参数 θ_i 的极大似然估计量
- 求解方法:
 - 求解对数似然方程 $\frac{\partial \ln L(\theta_1, \theta_2, \dots, \theta_k)}{\partial \theta_i} = 0 (i = 1, 2, \dots, k)$, 若驻点唯一, 即为极大似然估计
 - 根据定义计算
- 设 θ 的函数 $u = u(\theta)$, $\theta \in \Theta$ 具有单值反函数 $\theta = \theta(u)$, $u \in \mu$, 且 $\hat{\theta}$ 是参数 θ 的极大似然估计, 则 $\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ 的极大似然估计

估计量的评选标准

• 无偏性

若估计量 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 的数学期望 $E(\hat{\theta})$ 存在, 且 $\forall \theta \in \Theta, E(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 为 θ 的无偏估计量

若 $\lim_{n \rightarrow \infty} E\hat{\theta} = \theta$, 则称 $\hat{\theta}$ 为 θ 的渐近无偏估计

• 有效性

若 $E\hat{\theta}_1 = E\hat{\theta}_2 = \theta$, 若有 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$, 则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效

所有无偏估计中方差最小的无偏估计称为最小方差无偏估计, 或称为有效估计

- 总体 $X \sim f(x; \theta)$, 若 $E\hat{\theta} = \theta$, 则 $D(\hat{\theta}) \geq \frac{1}{nI(\theta)}$ (G-R下界), 其中Fisher信息数

$$I(\theta) = E\left[\frac{\partial}{\partial \theta} \ln f(X, \theta)\right]^2$$

若 $D(\hat{\theta}) = \frac{1}{nI(\theta)}$, 则称 $\hat{\theta}$ 为 θ 的有效估计

若 $\lim_{n \rightarrow \infty} \frac{\frac{1}{nI(\theta)}}{D(\hat{\theta})} = 1$, 则称 $\hat{\theta}$ 为 θ 的渐近有效估计

• 相合性 (一致估计)

若 $\hat{\theta}(X_1, X_2, \dots, X_n) \xrightarrow{P} \theta$, 即 $\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(|\hat{\theta} - \theta| \geq \varepsilon) = 0$, 则称 $\hat{\theta}$ 为 θ 的相合估计量

- 所有的矩估计都是相合估计

若 $\lim_{n \rightarrow \infty} D\hat{\theta} = 0, \lim_{n \rightarrow \infty} b(\theta) = \lim_{n \rightarrow \infty} (E\hat{\theta} - \theta) = 0$, 则 $\hat{\theta}$ 为 θ 的相合估计量

$$D\bar{X} = \frac{1}{n}DX$$

区间估计

• 定义

设总体 $X \sim f(x; \theta)$, 其中 θ 未知, 若对于给定的 $0 < \alpha < 1$, 统计量 $\hat{\theta}_1 = \hat{\theta}_1(X_1, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, \dots, X_n)$ 满足 $P(\hat{\theta}_1 < \theta < \hat{\theta}_2) = 1 - \alpha$, 则称随即区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 是 θ 的置信度为 $1 - \alpha$ 的置信区间, $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 分别称为置信度为 $1 - \alpha$ 的置信上限和置信下限, $1 - \alpha$ 称为置信度或置信水平

- 置信区间不唯一
- 置信区间长度越短, 估计越精确, 所以一般我们是对称的取, 此时的置信区间长度最短

• 求置信区间 (枢轴量法)

- 设法构造一个随机变量 $Z = Z(X_1, X_2, \dots, X_n; \theta)$, 除参数外, Z 不包含其他任何未知参数, Z 的分布已知或可求出, 并且不依赖于参数 θ , 也不依赖于其他任何未知参数 (Z 即称为枢轴量)

- 对于给定的置信度 $1 - \alpha$, 求出 a, b , 使得 $P\{a < Z(X_1, \dots, X_n; \theta) < b\} = 1 - \alpha$
- 由不等式 $a < Z(X_1, \dots, X_n; \theta) < b$ 解得 $\hat{\theta}_1(X_1, \dots, X_n) < \theta < \hat{\theta}_2(X_1, \dots, X_n)$, 即 $P(\hat{\theta}_1 < \theta < \hat{\theta}_2) = 1 - \alpha$

正态总体参数的区间估计

• 单个正态总体参数的区间估计

总体 $X \sim N(\mu, \sigma^2)$

被估参数	条件	选用统计量	分布	$1 - \alpha$ 的置信区间
μ	σ^2 已知	$U = \frac{\bar{X} - \mu}{\sigma} \sqrt{n}$	$N(0, 1)$	$\left[\bar{X} - \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}}, \bar{X} + \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}} \right]$
μ	σ^2 未知	$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}}$	$t(n-1)$	$\left[\bar{X} - \frac{s}{\sqrt{n}} t_{\frac{\alpha}{2}}, \bar{X} + \frac{s}{\sqrt{n}} t_{\frac{\alpha}{2}} \right]$
σ^2	μ 未知	$\chi^2 = \frac{(n-1)S^2}{\sigma^2}$	$\chi^2(n-1)$	$\left[\frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)} \right]$

◦ 若 $g(x)$ 单调增, 则 $P(\hat{\theta}_1 < \theta < \hat{\theta}_2) = 1 - \alpha \implies P(g(\hat{\theta}_1) < g(\theta) < g(\hat{\theta}_2)) = 1 - \alpha$

若 $g(x)$ 单调减, 则 $P(\hat{\theta}_1 < \theta < \hat{\theta}_2) = 1 - \alpha \implies P(g(\hat{\theta}_2) < g(\theta) < g(\hat{\theta}_1)) = 1 - \alpha$

• 两个正态总体的区间估计

$N \sim N(\mu_1, \sigma_1^2), Y \sim (\mu_2, \sigma_2^2)$ 相互独立

参数	条件	$1 - \alpha$ 的置信区间
$\mu_1 - \mu_2$	σ_1^2, σ_2^2 已知	$\left[\bar{X} - \bar{Y} - u_{\frac{\alpha}{2}} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}, \bar{X} - \bar{Y} + u_{\frac{\alpha}{2}} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}} \right]$
$\mu_1 - \mu_2$	$\sigma_1 = \sigma_2 = \sigma$ 未知	$\left[\bar{X} - \bar{Y} - t_{\frac{\alpha}{2}} S_{\varpi} \sqrt{\frac{1}{m} + \frac{1}{n}}, \bar{X} - \bar{Y} + t_{\frac{\alpha}{2}} S_{\varpi} \sqrt{\frac{1}{m} + \frac{1}{n}} \right]$
$\frac{\sigma_1^2}{\sigma_2^2}$	μ_1, μ_2 未知	$\left[\frac{S_1^2}{S_2^2} \cdot \frac{1}{F_{\frac{\alpha}{2}}(m-1, n-1)}, \frac{S_1^2}{S_2^2} \cdot \frac{1}{F_{1-\frac{\alpha}{2}}(m-1, n-1)} \right]$

假设检验

基本概念

• 基本思想

- 假设某个结论成立
- 小概率事件在一次抽样过程中发生了/一次抽样中没有发生小概率事件
- 认为原假设不成立/接受原假设

• 一般步骤

- 根据实际问题提出原假设 H_0 及备择假设 H_1
- 选择适当统计量, 在 H_0 条件下决定统计量分布
- 对给定的显著性水平 $0 < \alpha < 1$, 根据 $P((X_1, X_2, \dots, X_n) \in S | H_0) = \alpha$ 确定拒绝域 S

- 一旦得到一组样本观察值 (x_1, x_2, \dots, x_n) , 若 $(x_1, x_2, \dots, x_n) \in S$, 则拒绝 H_0 , 否则接受 H_0
- 假设检验的两类错误
 - 第一类错误: 如果原假设 H_0 成立, 而观察值落入拒绝域, 从而作出拒绝 H_0 的结论, 称作第一类错误, 又称弃真的错误。由定义知, 显著性水平 α 恰好是犯第一类错误的概率
 - 第二类错误: 如果原假设 H_0 不成立, 而观察值却落入接受域, 从而作出接受 H_0 的结论, 称作第二类错误, 又称取伪的错误, 通常记作 β 。

一般按照控制犯第一类错误的原则进行检验而不考虑犯第二类错误（保护原假设的原则），这种检验问题 称为显著性检验问题

单个正态总体参数的检验

总体 $X \sim N(\mu, \sigma^2)$, (X_1, \dots, X_n) 是一组样本

- σ^2 已知, 检验 μ
 - $H_0: \mu = \mu_0, H_1: \mu \neq \mu_0$, 双边检验
 - 假设 H_0 成立
 - 当 $\mu = \mu_0$ 时, 统计量 $U = \frac{\bar{X} - \mu}{\sigma} \sqrt{n} \sim N(0, 1)$ 分布已知
 - $P\left(\left|\frac{\bar{X} - \mu}{\sigma} \sqrt{n}\right| \geq k \mid H_0\right) \leq \alpha$, 满足该不等式则为 H_0 的拒绝域
 - 令 $k = u_{\frac{\alpha}{2}}$, 最大允许拒绝域为 $S = \left\{(x_1, \dots, x_n) \mid \left|\frac{\bar{X} - \mu_0}{\sigma} \sqrt{n}\right| \geq u_{\frac{\alpha}{2}}\right\}$
 - $H_0: \mu \leq \mu_0, H_1: \mu > \mu_0$, 单边右检验
 - 假设 H_0 成立
 - 当 $\mu \leq \mu_0$ 时, 统计量 $U = \frac{\bar{X} - \mu}{\sigma} \sqrt{n} \sim N\left(\frac{\mu - \mu_0}{\sigma} \sqrt{n}, 1\right)$ 分布已知
 -
 - $P\left(\frac{\bar{X} - \mu_0}{\sigma} \sqrt{n} \geq k \mid H_0\right) = P\left(\frac{\bar{X} - \mu}{\sigma} \sqrt{n} \geq k - \frac{\mu - \mu_0}{\sigma} \sqrt{n} \mid H_0\right) \leq P\left(\frac{\bar{X} - \mu}{\sigma} \sqrt{n} \geq k \mid H_0\right) \leq \alpha$, 满足该不等式则为 H_0 的拒绝域
 - 令 $k = u_\alpha$, 最大允许拒绝域为 $S = \left\{(x_1, \dots, x_n) \mid \frac{\bar{X} - \mu_0}{\sigma} \sqrt{n} \geq u_\alpha\right\}$

H_0	H_0 真时统计量的分布
$\mu = \mu_0$	$U = \frac{\bar{X} - \mu_0}{\sigma} \sqrt{n} \sim N(0, 1)$

H_1	拒绝 H_0 的区域
$\mu \neq \mu_0$	$ U \geq u_{\frac{\alpha}{2}}$
$\mu > \mu_0$	$U \geq u_\alpha$
$\mu < \mu_0$	$U \leq -u_\alpha$

- σ^2 未知, 检验 μ

H_0	H_0 真时统计量的分布
$\mu = \mu_0$	$T = \frac{\bar{X} - \mu_0}{S} \sqrt{n} \sim t(n-1)$

H_1	拒绝 H_0 的区域
$\mu \neq \mu_0$	$ T \geq t_{\frac{\alpha}{2}}(n-1)$
$\mu > \mu_0$	$T \geq t_{\alpha}(n-1)$
$\mu < \mu_0$	$T \leq -t_{\alpha}(n-1)$

- μ 已知, 检验 σ^2

H_0	H_0 真时统计量的分布
$\sigma^2 = \sigma_0^2$	$\chi^2 = \frac{1}{\sigma_0^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$

H_1	拒绝 H_0 的区域
$\sigma^2 = \sigma_0^2$	$\chi^2 \leq \chi_{1-\frac{\alpha}{2}}^2, \chi^2 \geq \chi_{\frac{\alpha}{2}}^2$
$\sigma^2 > \sigma_0^2$	$\chi^2 \geq \chi_{\alpha}^2(n)$
$\sigma^2 < \sigma_0^2$	$\chi^2 \leq \chi_{1-\alpha}^2(n)$

- μ 未知, 检验 σ^2

H_0	H_0 真时统计量的分布
$\sigma^2 = \sigma_0^2$	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma_0} \right)^2 \sim \chi^2(n-1)$

H_1	拒绝 H_0 的区域
$\sigma^2 = \sigma_0^2$	$\chi^2 \leq \chi_{1-\frac{\alpha}{2}}^2, \chi^2 \geq \chi_{\frac{\alpha}{2}}^2$
$\sigma^2 > \sigma_0^2$	$\chi^2 \geq \chi_{\alpha}^2(n-1)$
$\sigma^2 < \sigma_0^2$	$\chi^2 \leq \chi_{1-\alpha}^2(n-1)$